

Más allá de la black box: La explicabilidad en IA como un proceso de individuación técnica y transducción

Presentado por:

Edgar Santiago Suarez Alzate

Director:

Carlos Andrés Cortissoz Mora

Universidad Nacional de Colombia

Facultad de Ciencias Humanas

Departamento de Filosofía

2026

Índice general

Introducción	1
Primera parte: Genealogía técnica de la inteligencia artificial	2
Método a utilizar	2
¿De qué objeto es esta historia?	3
1. El sueño de la mente calculante	4
I. Una prehistoria de la IA	4
II. Turing y el calculista humano	5
III. El primer modelo matemático de la neurona	7
IV. La cibernética	8
Conclusiones	10

Introducción

Primera parte: Genealogía técnica de la inteligencia artificial

Método a utilizar

Las historias de la inteligencia artificial suelen contarse como una sucesión de hitos, como un artículo fundacional, un taller, una máquina que asombra a la prensa, un libro que la condena, un invierno, un renacimiento o un modelo que vence a un campeón de un juego. Esa forma de narrar la historia tiene la virtud de la claridad, pero considero que arrastra un supuesto que casi nunca se examina, siendo que los objetos técnicos de la historia -el perceptrón, el sistema experto, la red profunda, el Transformer- son productos acabados que se reemplazan unos a otros según eficacia, como modelos sucesivos de un mismo aparato. Esta primera parte parte de un supuesto distinto tomado de Gilbert Simondon: que un objeto técnico solo puede conocerse adecuadamente si se capta el sentido temporal de su evolución, y que por eso el método adecuado no es la clasificación de objetos ya hechos en géneros y especies, sino el estudio de su génesis. En una nota de El modo de existencia de los objetos técnicos, Simondon lo dice de una forma más precisa. Parafraseo la nota: el punto de usar un método genético es evitar la clasificación que opera después de la génesis, porque las relaciones entre objetos técnicos son tanto horizontales como verticales, y por ello la relación entre ellos es transductiva (Simondon, 2017, p. 26). Conviene subrayar desde ya ese último término, porque es el que esta monografía intentará llevar, en su tercera parte, hasta la idea de una explicabilidad transductiva.¹

Lo que esta primera parte intenta es aplicar ese método a la inteligencia artificial: preguntar en cada momento, qué incompatibilidad forzó el salto, qué medio lo hizo posible, qué se heredó y qué

¹En este escrito estoy siguiendo la estructura tentativa que se planteó en la última reunión para la monografía: Primera parte: realizar una construcción de la historia de la inteligencia artificial buscando aplicar la tesis y las ideas principales de G. Simondon; Segunda parte: aquí se va a explicar qué propone el artículo de Nested Learning sin usar tanto tecnicismo, o al menos, haciendo que sea entendible para un lector sin conocimientos técnicos. Adicionalmente, otro objetivo de esta segunda parte será leer la propuesta de Nested Learning con el aparato construido en la primera parte; Tercera parte: exponer y problematizar los métodos de la inteligencia artificial explicable, con el objetivo de proponer, si la argumentación lo permite, una explicabilidad transductiva.

se perdió, y qué tendencia -si la hay- atraviesa la serie completa.²

Antes de usar el vocabulario de Simondon conviene hacer una distinción que Hui señala y que suele pasarse por alto. En El modo de existencia de los objetos técnicos habla de la individualización de los objetos técnicos, no de su individuación. La individualización concierne a las funciones y exige una jerarquía que pone a los elementos en un orden de funcionamiento. En cambio, la individuación concierne a la génesis y a la resolución de tensiones hasta llegar a un equilibrio metaestable que se expresa como cambios de fase (Hui, 2016a, pp. 14-15). Simondon usa bastante un ejemplo relacionado a la cristalización. Este ejemplo consiste en: una solución sobresaturada está en estado metaestable, y basta una pequeña perturbación para que comience a cristalizar; los cristales ya formados sirven de base para la cristalización siguiente, y el proceso exige condiciones energéticas, materiales e informacionales (Hui, 2016a, p. 15). Hui propone, frente a Simondon, pensar no sólo la individualización sino la individuación de los objetos digitales (Hui, 2016a, p. 15).

Esta distinción permite decir con precisión que la historia de la inteligencia artificial tiene dos registros que conviene no confundir. Hay una historia de la individualización de sus objetos: cómo pasan de ser conjuntos de piezas con funciones separadas a ser sistemas coherentes, cómo se relacionan con su medio, cómo se distribuyen entre elemento, individuo y conjunto. Y hay una historia de la individualización del campo: cómo se acumula una tensión en un sistema metaestable -una disciplina, una comunidad, una infraestructura, un corpus de datos- hasta que un germen la hace cristalizar en una forma nueva. El lector verá que ambos registros se cruzan, y que uno de los hallazgos de esta parte es que el objeto más característico de la inteligencia artificial contemporánea -el modelo entrenado- se parece mucho a un cristal.

¿De qué objeto es esta historia?

Las historias de la inteligencia artificial presentan una dificultad la cual consiste en que no está claro cuál es el objeto técnico cuya historia se cuenta. No es una máquina, como en los ejemplos de Simondon. No es tampoco un formato, como en el caso de Hui. Considero que es una serie de esquemas -la unidad que dispara al superar un umbral, la regla "si..., entonces...", la señal de error que se propaga hacia atrás, el mecanismo de atención- que se encarnan sucesivamente en programas, en circuitos, en grandes infraestructuras. Simondon va a ayudar a resolver la búsqueda del objeto técnico dando una pista: el comienzo de un linaje de objetos técnicos está marcado por un acto sintético de invención constitutivo de una esencia técnica, y esa esencia se reconoce porque permanece estable a través del linaje y porque es productiva de estructuras y funciones (Simondon, 2017, p. 46). Esta parte tomará como objeto de su historia, entonces, no las máquinas sino los

²Las traducciones de las citas de obras en inglés son hechas por mí

esquemas y sus linajes, y tomará en serio la observación de Hui de que un objeto técnico, entendido ontológicamente, es una unidad de relaciones, y que su perfección es también el desarrollo de sus relaciones (Hui, 2016a, p. 14).

Es necesario hacer notar que Simondon construyó su aparato conceptual pensando en máquinas de energía, y Hui tuvo que adaptarlo para pensar objetos digitales. Aquí entonces hay que adaptarlo otra vez, porque los objetos de la inteligencia artificial contemporánea tienen un rasgo que ni los motores de Simondon ni los documentos de Hui tienen, me refiero a que su estructura interna se modifica durante el entrenamiento a partir de los datos. Un modelo entrenado no es solo fabricado, sino que es, en parte, formado por aquello que procesa. Este rasgo obliga, como se verá hacia el final de esta parte, a pregunta si "lo entrenado" no constituye un modo de génesis distinto tanto de lo producido como de lo engendrado.

Hui ha propuesto en *The Question Concerning Technology in China* una antinomia que conviene tener presente: o la técnica es antropológicamente universal, y las diferencias culturales solo modulan una tendencia técnica común, o la técnica no es universal y está afectada por las comprensiones cosmológicas de cada cultura, de modo que toda técnica es siempre cosmotécnica, es decir, unificación del orden cósmico y el orden moral a través de actividades técnicas (Hui, 2016b, p. 19). La historia que sigue es la historia de un linaje dominante, mayoritariamente angloamericano, y no la historia de la inteligencia artificial. Donde sea pertinente se señalarán las genealogías laterales que esa historia deja fuera.

1. El sueño de la mente calculante

I. Una prehistoria de la IA

Toda historia seria de la inteligencia artificial empieza antes de que existiera la computación electrónica, porque la idea de que el razonamiento pueda reducirse a cálculo es vieja. Aristóteles sistematizó las reglas del silogismo, es decir, la idea de que de premisas verdaderas pueden derivarse conclusiones verdaderas. Leibniz soñó con una *characteristica universalis*, un lenguaje simbólico con el que las disputas conceptuales podrían resolverse calculando, y construyó una máquina capaz de multiplicar y dividir. George Boole, en 1854, mostró que las operaciones del pensamiento lógico pueden expresarse algebraicamente. Charles Babbage diseñó en la década de 1830 una máquina analítica programable, y Ada Lovelace, al comentarla en 1843, advirtió a la vez su generalidad -podría operar sobre cualquier cosa representable simbólicamente- y su límite -no podía originar nada por sí misma-.

Ahora, ¿qué nos podría decir Simondon sobre este inicio de la historia? Considero que este inicio, aunque podría considerarse apropiadamente como una "prehistoria", no es todavía la historia

de un objeto técnico. Es más bien una carga preindividual, es decir, un campo de tensión entre el pensamiento y el mecanismo que no ha encontrado todavía el germen que le permite cristalizar. Leibniz tiene la idea de un cálculo del pensamiento y tiene una máquina de calcular, pero no tiene la noción que las une. Se puede ver también con Boole, el cual tiene el álgebra, pero no la máquina. Babbage padece lo mismo, puesto que tiene la máquina pero no tiene la teoría de sus límites. Esto evidencia que la tensión existe, que es real y también fecunda, pero permanece en estado metaestable. Lo que el siglo XX aportará no es una idea nueva sino el germen que hace cristalizar esa tensión en un objeto técnico definido. Y ese germen, como se verá, llega por dos vías casi simultáneas y en apariencia opuestas.

II. Turing y el calculista humano

En 1936, en *On Computable Numbers, with an Application to the Entscheidungsproblem*, Alan Turing respondió a una pregunta de los fundamentos de la matemática -si existe un procedimiento mecánico capaz de decidir la verdad de cualquier enunciado matemático- y para hacerlo tuvo que definir con precisión qué es un procedimiento mecánico. El resultado fue la máquina que hoy lleva su nombre y, sobre todo, la idea de que es posible inventar una sola máquina capaz de computar cualquier secuencia computable (Turing, 1936, p. 241). La máquina universal es el primer objeto técnico -aunque sea un objeto de papel- en el que el pensamiento y el mecanismo se encuentran en una forma definida.

Una lectura habitual puede hacernos llevar a entender que Turing va de las instrucciones a la máquina, es decir, que parte de un procedimiento formal y pregunta qué dispositivo puede ejecutarlo. Esa lectura es correcta pero se queda corta, pues omite una parte que es filosóficamente importante. Turing no deduce su máquina de la lógica pura, sino que la construye a partir de la observación de una práctica humana existente. Esta práctica humana es la del calculista, la persona que hace cálculos con lápiz y papel. Cabe añadir que en esa época, el calculista era muchas veces una mujer contratada para ese oficio. El artículo lo dice explícitamente al comienzo: podemos comparar a un hombre en el proceso de computar un número real con una máquina que solo es capaz de un número finito de condiciones (Turing, 1936, p. 231). Y cuando, en la sección novena, justifica que su definición captura todo lo que intuitivamente llamaríamos computable, lo hace con un análisis de lo que hace ese calculista: computar, escribir, se hace normalmente escribiendo ciertos símbolos sobre papel (Turing, 1936, pp. 249-250). La máquina de Turing es, en este sentido preciso, la abstracción de un gesto humano. Por gesto humano me refiero al de alguien que mira un símbolo, cambia de estado mental, escribe otro símbolo y se desplaza de hoja.

Esto obliga a matizar la oposición que se desarrollará en el apartado siguiente. Turing no parte de la nada, puesto que también él tiene un objeto previo, también él reconstruye unas 'instruccio-

nes' a partir de algo que ya funciona. La diferencia está en qué toma como objeto. Turing abstrae una operación -una práctica, un modo de hacer con signos-, y McCulloch y Pitts abstraerán un órgano. Simondon ofrece un criterio para pensar esa diferencia. Según él, la verdadera relación analógica entre el hombre y la máquina no se da en el nivel del funcionamiento corporal -la máquina no se nutre, no percibe (esto puede discutirse, pues puede argumentarse que un modelo de visión "percibe" propiamente su entorno, y actuará de acuerdo a este), no descansa, y la literatura cibernética explota falsamente la apariencia de analogía-, sino entre el funcionamiento mental del hombre y el funcionamiento físico de la máquina, y esa analogía se revela sobre todo en la invención, pues inventar es hacer funcionar el propio pensamiento como podría funcionar una máquina (Simondon, 2017, p. 151). Leído con este criterio, el gesto de Turing se sitúa del lado de la analogía que Simondon considera legítima, es decir, la que relaciona una operación mental con una operación física. El de McCulloch y Pitts, como se verá, se sitúa en el terreno que Simondon considera sospechoso.

Hay una segunda tensión, más profunda, que el objeto de Turing introduce en esta historia y que la atraviesa hasta hoy. La máquina universal es, literalmente, una máquina que puede hacer lo que hacen todas las máquinas de su tipo. Simondon, en cambio, sostiene que la idea de una 'máquina de todas las máquinas' es un mito, esto debido a que los adoradores de la máquina suponen que aumentando y perfeccionando el automatismo se lograría interconectar todas las máquinas hasta constituir la máquina de todas las máquinas, cuando el automatismo es en realidad un grado bastante bajo de perfección técnica (Simondon, 2017, p. 17). No hay una máquina de todas las máquinas, aunque sí puede haber un pensamiento que abarque todas las máquinas (Simondon, 2017, p. 157). ¿Contradice el resultado de Turing a Simondon? No exactamente. La universalidad de Turing es una universalidad formal, es decir, toda función computable puede ser computada por la máquina universal, siempre que se le dé el programa adecuado y un tiempo y una memoria ilimitados. La universalidad que Simondon niega es una universalidad concreta, la universalidad de un objeto técnico real que, acoplado a un medio, a una energía, a unas condiciones materiales, sería capaz de todos los funcionamientos. Entre ambas universalidades se abre una brecha que la inteligencia artificial nunca ha cerrado y que reaparece, con otro nombre, en la aspiración contemporánea a una 'inteligencia artificial general'. Esta IAG es la esperanza de que la universalidad formal de cómputo se convierta, por acumulación de escala, en universalidad concreta del funcionamiento.

Catorce años después, en 1950, Turing publicó *Computing Machinery and Intelligence*, que abre con la pregunta '¿pueden pensar las máquinas?' y propone sustituirla por un juego de imitación en el que un interrogador debe distinguir, mediante preguntas escritas, entre una persona y una máquina (Turing, 1950, p. 433). Suele olvidarse que el artículo termina con una sección sobre máquinas que aprenden, donde Turing propone que en lugar de intentar producir un programa que simule la mente adulta, ¿por qué no intentar producir uno que simule la mente de un niño? (Turing,

1950, p. 456). El padre de la línea que va 'de la especificación a la máquina' es también quien imagina, en el mismo gesto, su superación por una máquina que se forma a sí misma a partir de la experiencia. Las dos líneas que esta historia va a seguir no son dos escuelas enfrentadas desde el origen, sino que más bien están, en germen, en el mismo texto.

III. El primer modelo matemático de la neurona

En 1943, Warren McCulloch y Walter Pitts publicaron *A Logical Calculus of the Ideas Immanent in Nervous Activity*. El artículo abre con una frase que resume su programa entero: debido al carácter de "todo o nada" de la actividad nerviosa, los eventos neuronales y las relaciones entre ellos pueden tratarse por medio de la lógica proposicional (McCulloch y Pitts, 1943, p. 115). A partir de ahí construyeron un modelo formal de la neurona -una unidad que recibe señales de otras unidades y dispara si un número suficiente de ellas está activo en un intervalo dado- y demuestran que redes de esas unidades pueden computar funciones lógicas arbitrarias.

Como lo propuso mi director, el gesto de McCulloch y Pitts puede leerse como el inverso del de Turing. Turing parte de una operación y pregunta qué máquina puede ejecutarla. McCulloch y Pitts parten de un objeto que ya existe y ya funciona, la neurona biológica, cuyo comportamiento podemos observar aunque sus reglas internas no se dejen ver directamente, y preguntan qué instrucciones explicarían ese comportamiento. El objeto es lo dado y las instrucciones son lo que hay que encontrar, de modo que estamos ante un ejercicio de ingeniería inversa sobre una máquina que la naturaleza ya construyó.

Leyendo el artículo con cuidado aparece un problema que complica esa inversión, y considero que es el primer problema filosófico serio de esta historia. McCulloch y Pitts no dejan que la neurona les dicte sus reglas. Llegan a ella con la lógica proposicional ya en la mano y encuentran en ella justamente lo que traían. Sus cinco supuestos físicos lo muestran: la actividad de la neurona es un proceso de "todo o nada"; un número fijo de sinapsis debe excitarse para activarla; el único retraso significativo es el sináptico; la inhibición es absoluta; y la estructura de la red no cambia con el tiempo (McCulloch y Pitts, 1943, p. 118). Cada uno de esos supuestos hace a la neurona compatible con el álgebra de Boole. El resultado final lo confirma, puesto que ellos mismos demuestran que toda red, dotada de una cinta, de escáneres conectados a sus aferencias y de eferencias adecuadas, solo puede computar los números que puede computar una máquina de Turing (McCulloch y Pitts, 1943, p. 129). El gesto que partió del órgano termina en el procedimiento.

Hui recuerda que el proyecto de Simondon comienza rechazando el hilemorfismo, ese esquema que piensa los objetos como una forma que se impone sobre una materia y que está emparentado con el pensamiento de sustancia y predicado, debido a que es una forma ya individuada la que le da a la materia su esencia (Hui, 2016a, pp. 12-13). La operación de McCulloch y Pitts es hilemórfica en ese

sentido, ya que la neurona es la materia y la lógica proposicional es la forma que se le impone. No lo digo como reproche, puesto que el artículo fue extraordinariamente fecundo, sino porque conviene nombrar un rasgo que se va a repetir. La tentación de encontrar en el objeto modelado la forma que el modelador ya tenía acompaña a toda la historia de la inteligencia artificial, y reaparecerá cada vez que se diga que una red 'razona', 'recuerda' o 'sufre de amnesia'.

Hay dos detalles del artículo que quiero conservar, porque anticipan el final de esta historia. El primero es el quinto supuesto, el de que la estructura de la red no cambia con el tiempo (McCulloch y Pitts, 1943, p. 118). La primera red neuronal formal de la historia es una red que no aprende, con sus conexiones fijadas de antemano y lo que puede hacer determinado por su diagrama de cableado. La historia de la inteligencia artificial empieza entonces con una red estática y termina, por ahora, con modelos cuyos parámetros quedan congelados una vez entrenados. El segundo detalle está en la sección final, donde los autores sacan consecuencias epistemológicas de su modelo y concluyen que nuestro conocimiento del mundo, incluidos nosotros mismos, es incompleto en cuanto al espacio e indefinido en cuanto al tiempo (McCulloch y Pitts, 1943, p. 129). Un artículo que se propone dar el cálculo lógico de las ideas termina con una tesis sobre lo incompleto de nuestro conocimiento.

IV. La cibernética

Entre el artículo de McCulloch y Pitts y el taller de Dartmouth hay una década que las historias de la inteligencia artificial suelen resolver en una línea, y que sin embargo fue el medio de cultivo de todo lo que vino después. Me refiero a la cibernética. Norbert Wiener publicó *Cybernetics* en 1948, y entre 1946 y 1953 las conferencias Macy reunieron a matemáticos, neurofisiólogos, antropólogos y psiquiatras -McCulloch y Pitts entre ellos- alrededor de una intuición común, la de que la comunicación y el control en los seres vivos y en las máquinas podían estudiarse con los mismos conceptos de información, retroalimentación y regulación. W. Ross Ashby construyó su homeostato, y William Grey Walter construyó unas tortugas robóticas que buscaban la luz y volvían a recargarse.

Simondon fue un lector atento y crítico de la cibernética, y su crítica ilumina un problema que la inteligencia artificial heredó sin resolver. Por un lado le reconoce el inmenso mérito de ser el primer estudio inductivo de los objetos técnicos y de presentarse como estudio del dominio intermedio entre las ciencias especializadas (Simondon, 2017, p. 51). Por otro lado señala su error de partida, que es el postulado de la identidad entre los seres vivos y los objetos técnicos autorregulados, junto con la aceptación de una clasificación por géneros y especies -la de los 'autómatas'- que una verdadera tecnología debería rechazar, debido a que los autómatas no son una especie y lo único que hay son objetos técnicos con distintos grados de automatismo (Simondon, 2017, p. 51). Más adelante insiste en que los cibernetas han tendido a forzar a los seres técnicos a copiar a los vivos

construyendo seres semejantes a ellos, una posibilidad que califica de suposición sin fundamento (Simondon, 2017, p. 71).

Esta crítica importa aquí por dos razones. La primera es que la inteligencia artificial nació, en parte, como un desprendimiento de la cibernética, ya que John McCarthy reconocería años después que eligió el nombre 'inteligencia artificial' también para no quedar bajo la sombra de Wiener y de su vocabulario. El campo se funda con un gesto de separación respecto de su medio de origen, y esa separación tuvo consecuencias, puesto que la tradición simbólica dejó atrás la retroalimentación, la regulación y el acoplamiento con el entorno para concentrarse en el símbolo y la búsqueda. La segunda razón es que el postulado que Simondon le reprocha a la cibernética no desapareció con ella. Sobrevivió en el vocabulario del conexionismo -'neuronas', 'aprendizaje', 'memoria'- y llega intacto hasta el artículo sobre Nested Learning que ocupa la segunda parte de esta monografía, que se inspira explícitamente en la neuroplasticidad y en las oscilaciones cerebrales. Simondon ofrece aquí una advertencia metodológica que tendré que tomar en serio más adelante: hay que evitar la identificación impropia del objeto técnico con el objeto natural y, más específicamente, con el ser vivo, y las analogías externas deben ser rigurosamente desterradas, debido a que no tienen significación y solo inducen a error (Simondon, 2017, p. 50).

La cibernética ofrece también el primer ejemplo de una genealogía lateral que la historia dominante excluye. En el Chile de Salvador Allende, entre 1971 y 1973, el ciberneta británico Stafford Beer dirigió el proyecto Cybersyn, un sistema para coordinar la economía nacional mediante flujos de información en tiempo real, y en la Unión Soviética Víktor Glushkov propuso en los años sesenta una red nacional de cómputo para la planificación económica. Ninguno de estos proyectos es 'inteligencia artificial' en el sentido que el término adquirió en Dartmouth, y justamente por eso importan, puesto que muestran que la misma carga preindividual -la tensión entre pensamiento, información y máquina- pudo cristalizar de otras maneras, orientada por otras cosmologías políticas. Si toda técnica es cosmotécnica, la historia que sigue es una cristalización posible entre otras.

Conclusiones